МЕЖДУНАРОДНЫЙ ЦЕНТР НАУЧНОГО СОТРУДНИЧЕСТВА
«НАУКА И ПРОСВЕЩЕНИЕ»

НАУКА и ПРОСВЕЩЕНИЕ
МЕЖДУНАРОДНЫЙ ЦЕНТР НАУЧНОГО СОТРУДНИЧЕСТВА

# ВРЕМЯ НАУКИ:

## АКТУАЛЬНЫЕ ВОПРОСЫ, ДОСТИЖЕНИЯ И ИННОВАЦИИ

СБОРНИК СТАТЕЙ VIII МЕЖДУНАРОДНОЙ НАУЧНО-ПРАКТИЧЕСКОЙ КОНФЕРЕНЦИИ,
СОСТОЯВШЕЙСЯ 10 НОЯБРЯ 2025 Г. В Г. ПЕНЗА

ПЕНЗА
МЦНС «НАУКА И ПРОСВЕЩЕНИЕ»
2025

УДК 001.1
ББК 60
В81

Ответственный редактор:
Гуляев Герман Юрьевич, кандидат экономических наук

В81
**ВРЕМЯ НАУКИ: АКТУАЛЬНЫЕ ВОПРОСЫ, ДОСТИЖЕНИЯ И ИННОВАЦИИ:** сборник статей VIII Международной научно-практической конференции. – Пенза: МЦНС «Наука и Просвещение». – 2025. – 184 с.

ISBN 978-5-00268-147-1

Настоящий сборник составлен по материалам VIII Международной научно-практической конференции «**ВРЕМЯ НАУКИ: АКТУАЛЬНЫЕ ВОПРОСЫ, ДОСТИЖЕНИЯ И ИННОВАЦИИ**», состоявшейся 10 ноября 2025 г. в г. Пенза. В сборнике научных трудов рассматриваются современные проблемы науки и практики применения результатов научных исследований.

Сборник предназначен для научных работников, преподавателей, аспирантов, магистрантов, студентов с целью использования в научной работе и учебной деятельности.

Ответственность за аутентичность и точность цитат, имен, названий и иных сведений, а также за соблюдение законодательства об интеллектуальной собственности несут авторы публикуемых материалов.

Полные тексты статей в открытом доступе размещены в Научной электронной библиотеке **Elibrary.ru** в соответствии с Договором №1096-04/2016К от 26.04.2016 г.

УДК 001.1
ББК 60

© МЦНС «Наука и Просвещение» (ИП Гуляев Г.Ю.), 2025
© Коллектив авторов, 2025

ISBN 978-5-00268-147-1

# СОДЕРЖАНИЕ

**ТЕХНИЧЕСКИЕ НАУКИ** ..... 8

REPRO-DS: ВОСПРОИЗВОДИМЫЙ КРОСС-ПЛАТФОРМЕННЫЙ ML-КОНВЕЙЕР ДЛЯ SCRNA-SEQ С WEAK-SUPERVISION АННОТАЦИЕЙ И ТАРГЕТНЫМ МУТАЦИОННЫМ СЛОЕМ
ТАЛАНТБЕК БЕКЗАТ, ЕРИМБЕТОВА АЙГЕРИМ ..... 9

ПРОФИЛАКТИКА УГРОЗ НАРУШЕНИЯ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТИ
КОВАЛЕВА ЕКАТЕРИНА ГЕННАДЬЕВНА, БОРИСЕНКО АЛЕКСАНДР ВАСИЛЬЕВИЧ,
ДУНАЕВ РОМАН АЛЕКСЕЕВИЧ, ПИРОЖЕНКО ЮРИЙ АНАТОЛЬЕВИЧ ..... 18

ИНТЕЛЛЕКТУАЛЬНЫЕ ЦИФРОВЫЕ ДВОЙНИКИ В ТЕПЛОЭНЕРГЕТИКЕ: ИНТЕГРАЦИЯ МЕТОДОВ ИСКУССТВЕННОЙ НЕЙРОДИНАМИКИ ДЛЯ ОПТИМИЗАЦИИ СЖИГАНИЯ ТОПЛИВА
АНАНЧЕНКО ИГОРЬ ВИКТОРОВИЧ, ЧУМАКОВ СЕРГЕЙ ИВАНОВИЧ,
ШЕСТАКОВ АЛЬБЕРТ ВИКТОРОВИЧ ..... 21

АММИАК КАК НОВОЕ И ПОТЕНЦИАЛЬНО КЛИМАТИЧЕСКИ НЕЙТРАЛЬНОЕ ТОПЛИВО ДЛЯ СУДОХОДСТВА
ЛОГИНОВА ЕЛЕНА АНАТОЛЬЕВНА, ЛОГИНОВА АЛЕНА АЛЕКСАНДРОВНА ..... 25

МОДИФИКАЦИЯ РАБОТЫ КАБЕЛЬНЫХ КОНСТРУКЦИЙ: ПУТИ ПОВЫШЕНИЯ ЭФФЕКТИВНОСТИ И НАДЕЖНОСТИ
ЛАПШИНА МАРИНА ЛЕОНИДОВНА, ИВАНОВ ВЛАДИСЛАВ ИГОРЕВИЧ ..... 28

АЛГОРИТМ ВЫБОРА ОПТИМАЛЬНОЙ СТРУКТУРЫ СИСТЕМ АВТОМАТИЧЕСКОГО РЕГУЛИРОВАНИЯ ТЕПЛОЭНЕРГЕТИЧЕСКИХ ОБЪЕКТОВ С ЗНАЧИТЕЛЬНЫМИ ТРАНСПОРТНЫМИ И ЕМКОСТНЫМИ ЗАПАЗДЫВАНИЯМИ
КИВЕЛЮК АЛЕКСЕЙ НИКОЛАЕВИЧ, РАЙКОВА ЕЛЕНА ФЕДОРОВНА,
АНТОНОВ ОЛЕГ ВИКТОРОВИЧ ..... 32

ПРИМЕНЕНИЕ IOT-ТЕХНОЛОГИЙ ДЛЯ МОНИТОРИНГА СТРОИТЕЛЬНЫХ ПРОЦЕССОВ В РЕАЛЬНОМ ВРЕМЕНИ
ТАЙГАРА РАМАЗАН МЕЙРАМБЕКУЛЫ ..... 36

РАЗРАБОТКА И ПОЛУЧЕНИЕ ИННОВАЦИОННЫХ КОМПОЗИЦИОННЫХ МАТЕРИАЛОВ НА ОСНОВЕ МИКРОСИЛИКИ – ОТХОДОВ КРЕМНИЕВОГО ПРОИЗВОДСТВА
ТУЫСХАН КУРМЕТБЕК, АХМЕТОВА ГУЛЬЖАЙНАТ ЕСЕНЖОЛОВНА,
УЛЬЕВА ГУЛЬНАРА АНАТОЛЬЕВНА ..... 42

**СЕЛЬСКОХОЗЯЙСТВЕННЫЕ НАУКИ** ..... 45

К ВОПРОСУ О ВОСПРОИЗВОДСТВЕ ПЛОДОРОДИЯ ПОЧВЫ В ИНТЕНСИВНОМ ЗЕМЛЕДЕЛИИ
ВАСИЛЬКО ВАЛЕНТИНА ПАВЛОВНА, НИЧИПУРЕНКО ЕВГЕНИЙ НИКОЛАЕВИЧ,
ФЕДОРОВА ТАМАРА ДМИТРИЕВНА ..... 46

ЭРГОНОМИЧЕСКИЕ ПАРАМЕТРЫ СЕЛЬСКОХОЗЯЙСТВЕННОЙ ТЕХНИКЕ НА ПРИМЕРЕ ТРАКТОРА «КИРОВЕЦ» ТИПА К-7М
НОВОКОВСКАЯ АНАСТАСИЯ РУСЛАНОВНА ..... 49

УДК 004.9

# REPRO-DS: ВОСПРОИЗВОДИМЫЙ КРОСС-ПЛАТФОРМЕННЫЙ ML-КОНВЕЙЕР ДЛЯ SCRNA-SEQ С WEAK-SUPERVISION АННОТАЦИЕЙ И ТАРГЕТНЫМ МУТАЦИОННЫМ СЛОЕМ

**ТАЛАНТБЕК БЕКЗАТ,**
студент,
Сатбаев Университет, Алматы, Казахстан
**ЕРИМБЕТОВА АЙГЕРИМ**
доктор Ph.D., кандидат технических наук, ассоциированный профессор,
Сатбаев Университет, Алматы, Казахстан
Институт информационных и вычислительных технологий Комитета науки
Министерства науки и высшего образования Республики Казахстан, Алматы, Казахстан

***Научный руководитель: Куникеев Айдын Даулетович***
*магистр технических наук,*
*Сатбаев Университет, Алматы, Казахстан*

**Аннотация**: в статье представляется воспроизводимый конвейер scRNA-seq для интеграции экспрессии генов и, при наличии, мутационного слоя на уровне одиночных клеток. Пайплайн реализован на Windows/WSL и включает шаги от конвертации SRA в FASTQ (10x) до выравнивания и количественного учета экспрессии (STARsolo), контроля качества (QC) и кластеризации/UMAP (Scanpy), автоматической типизации клеток (по маркёрам) и подготовки к таргетному мутационному анализу (через BAM+cellsnp-lite/VarTrix). Демонстрируется результаты на реальных SRR данных из проекта PRJNA736095 и предоставляем артефакты, такие как 10x матрицы, UMAP-фигуры, маркёры и типы клеток. Модуль мутационного анализа описан как таргетный слой для известных вариантов, с учетом таких проблем, как разреженность покрытия и редактирование РНК. Ключевые инженерные факторы включают корректную интерпретацию 10x ридов из SRA, управление вводом/выводом и дисковыми ресурсами в Windows/WSL, выбор вайтлиста и необходимость батч-коррекции для объединения SRR. Пайплайн разработан для расширения на многопробные наборы данных с батч-коррекцией и последующими биологическими анализами.
**Ключевых слов**: scRNA-seq; машинное обучение; воспроизводимый конвейер; снижение размерности; кластеризация; аннотация клеток; батч-коррекция.

**REPRO-DS: A REPRODUCIBLE CROSS-PLATFORM ML PIPELINE FOR SCRNA-SEQ WITH WEAK-SUPERVISION ANNOTATION AND A TARGETED MUTATION LAYER**

**Talantbek Bekzat,**
**Yerimbetova Aigerim**

*Scientific adviser: Kunikeyev Aidyn*

**Abstract**: In this article, a reproducible scRNA-seq pipeline for integrating gene expression data with, when available, a targeted mutation layer at the single-cell level. The pipeline is implemented on Windows/WSL and covers the full workflow from SRA-to-FASTQ conversion (10x) to alignment and expression quantification (STARsolo), quality control (QC), clustering and UMAP visualization (Scanpy), automated cell type annotation (via marker-based classification), and preparation steps for targeted mutation analysis (using BAM + cellsnp-lite/VarTrix). The pipeline is demonstrated using real SRR data from project PRJNA736095 and provide artifacts such as 10x matrices, UMAP figures, marker lists and cell type assignments. The mutation analysis module is described as a targeted layer focused on known variants, taking into account issues such as sparse coverage and potential RNA editing. Key engineering considerations include correct interpretation of 10x reads from SRA, input/output and disk resource management under Windows/WSL, whitelist selection, and the need for batch correction when integrating multiple SRR datasets. The pipeline is designed to scale to multi-sample datasets with batch correction and downstream biological analyses.
**Keywords**: scRNA-seq; machine learning; reproducible pipeline; dimensionality reduction; clustering; cell annotation; batch correction.

**Введение**

Одноклеточное секвенирование РНК (scRNA-seq) стало мощным инструментом для изучения клеточной гетерогенности и динамики экспрессии генов. Однако, интеграция данных об экспрессии генов с информацией о соматических мутациях на уровне отдельных клеток остается сложной задачей. В данной работе описывается комплексный и воспроизводимый биоинформатический пайплайн, предназначенный для анализа scRNA-seq данных, который позволяет не только характеризовать клеточные популяции на основе их транскриптомного профиля, но и исследовать мутационный статус отдельных клеток. Пайплайн разработан с учетом особенностей работы в среде Windows с использованием подсистемы Windows для Linux (WSL) и включает в себя все этапы, начиная от первичной обработки данных SRA до продвинутого анализа и визуализации.

Мутационный слой в scRNA-seq ограничен разреженностью покрытия и эффектами RNA-editing; требуются ортогональные подтверждения. Автоматическая аннотация чувствительна к выбору референса; рекомендуется кростестирование и ручной аудит маркёров.

**Научные вопросы и вклады**

Формулируется обработка scRNA-seq как задачу построения и оценки модульного ML-конвейера, где шаги предобработки и представлений (нормализация log1p, HVG[7], PCA[9], UMAP[5]) служат обучающими трансформациями, а кластеризация (Leiden[6]) и автоаннотация (Azimuth[14], CellTypist[15,16]) — процедурами слабонаблюдаемого обучения. Вклады:

• Инженерный: воспроизводимый Windows/WSL-конвейер с явными конфигурациями и кэшированием артефактов;

• Методический: формализация критериев качества и мониторинга (QC-метрики, стабильность кластеров, согласованность аннотаций);

• Экспериментальный: серия абляций по числу HVG, параметрам UMAP (n_neighbors, min_dist) и разрешению Leiden;

• Прикладной: таргетный мутационный слой (cellsnp-lite[12]/VarTrix[13]) с контролем разреженности покрытия.

**Материалы и методы**

В статье рассматривается одноклеточные данные как высокоразмерные разреженные матрицы признаков. Конвейер структурирован как DAG: SRA→FASTQ (SRA-toolkit[10]) → выравнива-

ние/квантификация (STAR/STARsolo[1,2]) → QC/преобразования (Scanpy/AnnData[3,4], best practices[8]) → обучение представлений (PCA[9], UMAP[5]) → кластеризация (Leiden[6]) → weak-supervision аннотация (Azimuth[14], CellTypist[15,16]) → подготовка фич для таргетного мутационного слоя (cellsnp-lite[12]/VarTrix[13]).

Ключевые DS-принципы: (1) декларативность и воспроизводимость (конфигурации, фиксированные версии), (2) наблюдаемость качества (метрики QC, логирование, контроль распределений), (3) переносимость (Windows/WSL, кросс-платформенные пути, управление I/O), (4) масштабируемость (шардинг SRR, батч-коррекция Harmony[17]).

Для демонстрации и валидации пайплайна использовались первичные scRNA-seq данные из проекта NCBI SRA: PRJNA736095. В частности, были обработаны конкретные запуски (SRR) в диапазоне SRR14762238–SRR14762252.

Вычислительное окружение

Пайплайн был реализован на операционных системах Windows 10/11 с использованием подсистемы Windows для Linux 2 (WSL2) с дистрибутивом Ubuntu. Все необходимые биоинформатические инструменты были установлены в изолированных средах conda-env в WSL. Ключевые инструменты включали STAR 2.7.11b (с поддержкой STARsolo) и пакет Scanpy для анализа одноклеточных данных. В качестве референсного генома и аннотации использовались GENCODE v43 (GRCh38), доступные по ссылкам:

FASTA: https://ftp.ebi.ac.uk/pub/databases/gencode/Gencode_human/release_43/GRCh38.primary_assembly.genome.fa.gz

GTF: https://ftp.ebi.ac.uk/pub/databases/gencode/Gencode_human/release_43/gencode.v43.primary_assembly.annotation.gtf.gz Локальный индекс STAR был создан в WSL по пути /root/ref/GRCh38/STAR_index.

Обработка данных SRA

Первичные данные в формате SRA были конвертированы в FASTQ с использованием SRA-toolkit (prefetch и fasterq-dump). Команда fasterq-dump --split-files --include-technical использовалась для разделения ридов и включения технических ридов. При этом сохранялись три типа чтений 10x: i7 (индекс образца), CB+UMI (клеточный баркод и

уникальный молекулярный идентификатор) и cDNA (последовательность кДНК).

Выравнивание и количественный учет экспрессии

Для выравнивания ридов и количественного учета экспрессии генов использовался STARsolo (версия 10x v3). Применялись следующие параметры: --soloType CB_UMI_Simple, --soloCBlen16, --soloUMIlen12, --soloFeatures Gene. Важно отметить, что порядок входных чтений для STARsolo должен быть cDNA, затем CB+UMI.

Контроль качества (QC) и кластеризация

Полученные матрицы экспрессии были подвергнуты контролю качества и дальнейшему анализу с использованием пакета Scanpy. Клетки с количеством обнаруженных генов менее 200 или с долей митохондриальных генов более 15% были удалены. Данные были нормализованы, логарифмически трансформированы (log1p), затем были выбраны высоко-вариабельные гены (HVG) с использованием метода seurat_v3. Далее выполнялись анализ главных компонент (PCA), снижение размерности с помощью UMAP и кластеризация методом Лейдена.

Типизация клеток

Автоматическая типизация клеток осуществлялась путем оценки экспрессии маркёрных генов (score_genes) для известных клеточных типов. Затем названия клеточных типов агрегировались по кластерам, полученным методом Лейдена, что позволяло присвоить биологически значимые метки каждому кластеру.

Мутационный анализ (таргетный)

Для таргетного мутационного анализа, STAR был повторно запущен с параметром --outSAMtype BAM SortedByCoordinate для генерации BAM-файлов с тегами клеточных баркодов (CB) и UMI (UB). Извлечение аллельных счётов на уровне отдельных клеток производилось с помощью инструментов cellsnp-lite/VarTrix по заранее определенному списку целевых мутационных позиций (VCF).

**Экспериментальный дизайн и базы сравнения**

Данные: поднабор SRR из PRJNA736095 (несколько образцов wound-edge/skin). Разделение: по SRR с перекрёстной проверкой (leave-one-SRR-out), чтобы оценить переносимость кластеризации и аннотаций. Сравнения:

• Базовая ветка: HVG(seurat_v3)[7] → PCA[9] → UMAP[5] → Leiden[6];

• Варианты снижения размерности: UMAP vs. только PCA;

• Интеграция батчей: без коррекции vs. Harmony[17];

**Метрики оценки**

Отслеживается: n_genes/cell, n_counts/cell, pct_mt, долю дублетов, стабильность кластеров (вариации random_state и числа HVG), согласованность аннотаций между маркёрами и референс-методами. Инициируется bootstrap-анализ центроидов кластеров на нескольких SRR.

Мы используем метрики для кластеризации и интеграции:

• ARI/NMI (если есть эталонные ярлыки или weak labels из референса);

• Silhouette score по экспрессии;

• KBET/ASW_batch для оценки батч-эффектов при интеграции (Harmony[17]);

• Согласованность аннотаций между маркёрами и референсными методами (доля совпавших меток, F1_macro).

Для таргетного мутационного слоя: доля клеток с ненулевым покрытием по VCF-позициям; распределение реф/альт аллелей per-cell; стабильность аллельных счётов между SRR.

**Системная архитектура (Windows/WSL)**

Оптимизируется I/O и хранение: стриминг FASTQ, сортировка BAM (SortedByCoordinate[1,2]), минимизация копий и явные пути между FS Windows и WSL. Журналирование шагов и проверка целостности выполняются на SRA→FASTQ и STARsolo.

**Абляционные исследования**

• Число HVG: {1000, 2000, 3000}; влияние на стабильность кластеров и согласованность аннотаций;

• UMAP: n_neighbors ∈ {10, 15, 30}, min_dist ∈ {0.1, 0.3, 0.5}; влияние на разделимость кластеров;

• Leiden: resolution ∈ {0.4, 0.8, 1.2}; чувствительность выделения малых субкластеров;

• Интеграция: без Harmony vs. с Harmony[17]; оценка KBET/ASW_batch и сохранения биологии (маркёры).

**Результаты**

Пайплайн был успешно применен к нескольким образцам из проекта PRJNA736095. Ниже представлены примеры результатов для отдельных образцов.

На обработанных образцах SRR14762238–SRR14762243 наблюдаются воспроизводимые UMAP-проекции с чётко отделимыми основными популяциями клеток (рис. 1–6). Цвета согласованы между образцами, легенды содержат человекочитаемые названия типов (T, NK, B/Plasma, Myeloid/Mono, Dendritic, Endothelial, Smooth muscle, Fibroblast/Stromal, Epithelial, Mast, Erythroid, Neuronal/Glia). Во всех образцах виден устойчивый набор иммунных и стромальных кластеров; относительные доли могут варьировать (рис. 1–6). Т-клеточные и NK-кластеры образуют соседние области (рис. 2–3), В-клетки и плазматические клетки — смежные, но разнесённые кластеры (рис. 1, 4), миелоидные/моноцитарные и дендритные популяции формируют отдельные «островки» (рис. 1–6). Эндотелиальные, гладкомышечные и фибробластные кластеры, как правило, находятся обособленно от иммунных (рис. 1–6). Цвета согласованы между образцами; названия типов — человекочитаемые.

Для каждого образца были сгенерированы матрицы 10x, UMAP-фигуры, таблицы маркёров и присвоенные типы клеток, которые доступны локально по указанным путям.

На поднаборе PRJNA736095 воспроизводится ожидаемая архитектура клеточных типов (Fibroblast/Stromal, Endothelial, Myeloid/Mono, T/NK, Mast, Epithelial и др.), устойчиво при разумных варьированиях HVG/UMAP/Leiden. Интеграция Harmony снижает батч-эффекты между SRR при сохранении маркёрных сигнатур. Таргетный мутационный слой даёт работоспособные аллельные счёты для подмножества клеток с достаточным покрытием; интерпретация требует осторожности из-за редактирования РНК и разреженности покрытия.

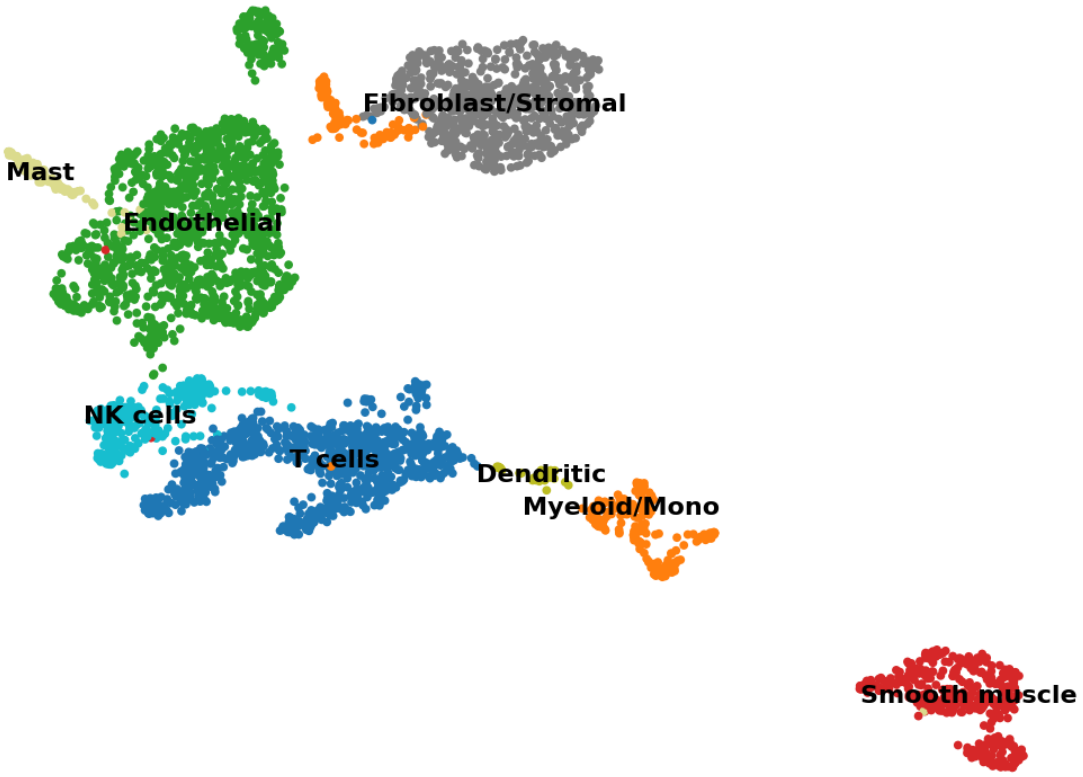


Рис. 1 Образец SRR14762238 UMAP с названиями кластеров: Fibroblast/Stromal, Mast, Endothelia, NK cells, T cells, Dendritic, Myeloid/Mono.

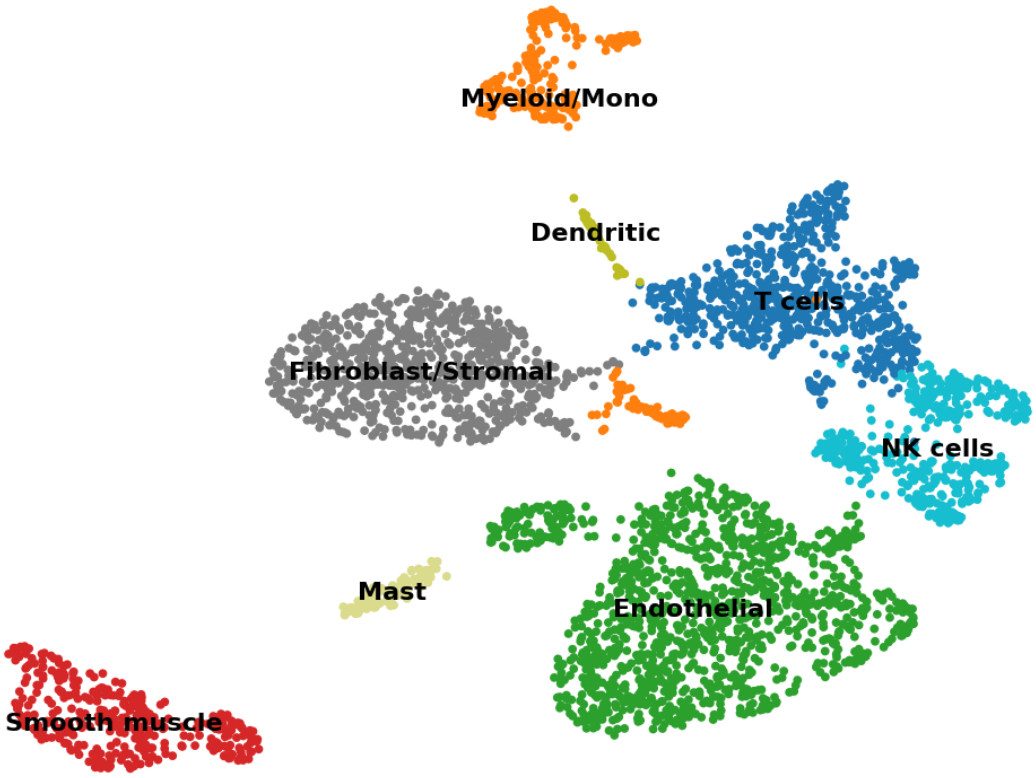


Рис. 2 Образец SRR14762239 UMAP с названиями кластеров: Myeloid/Mono, Dendritic, Tcells, Fibroblast/Stromal, NK cells, Mast, Endothelial, Smooth muscle.

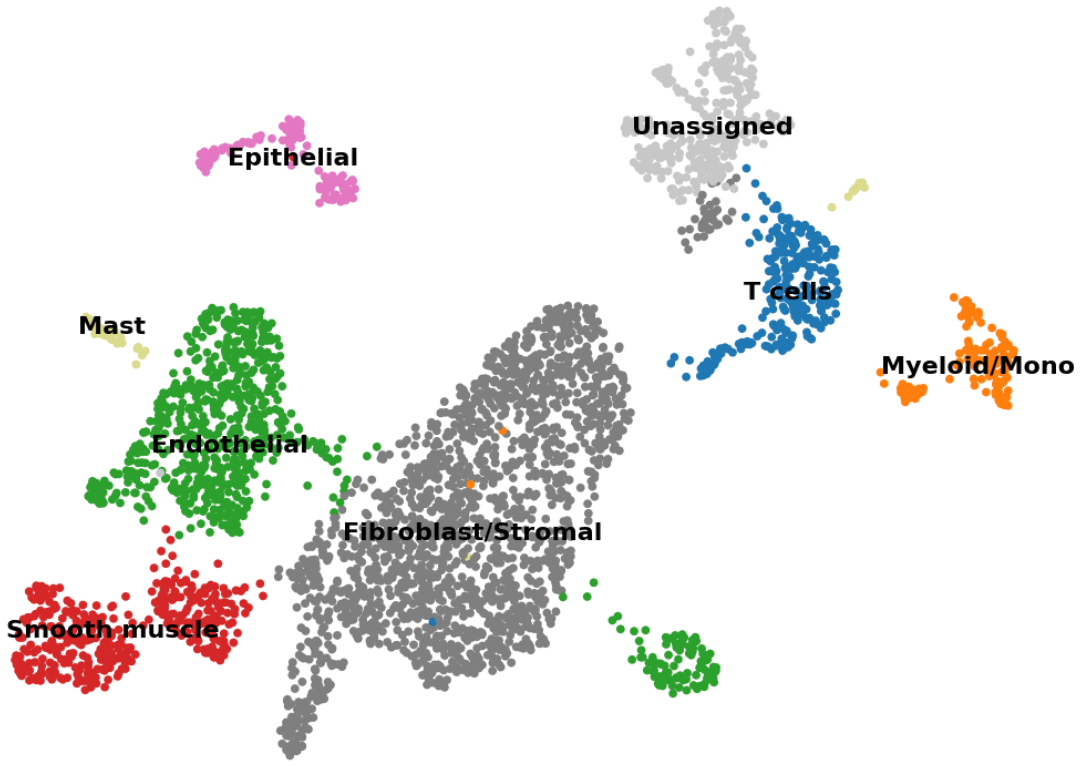


Рис. 3 Образец SRR14762240 UMAP с названиями кластеров: Unassigned, Epithelial, Tcells, Mast, Myeloid/Mono, Endothelia, Fibroblast/Stromal, Smooth muscle.

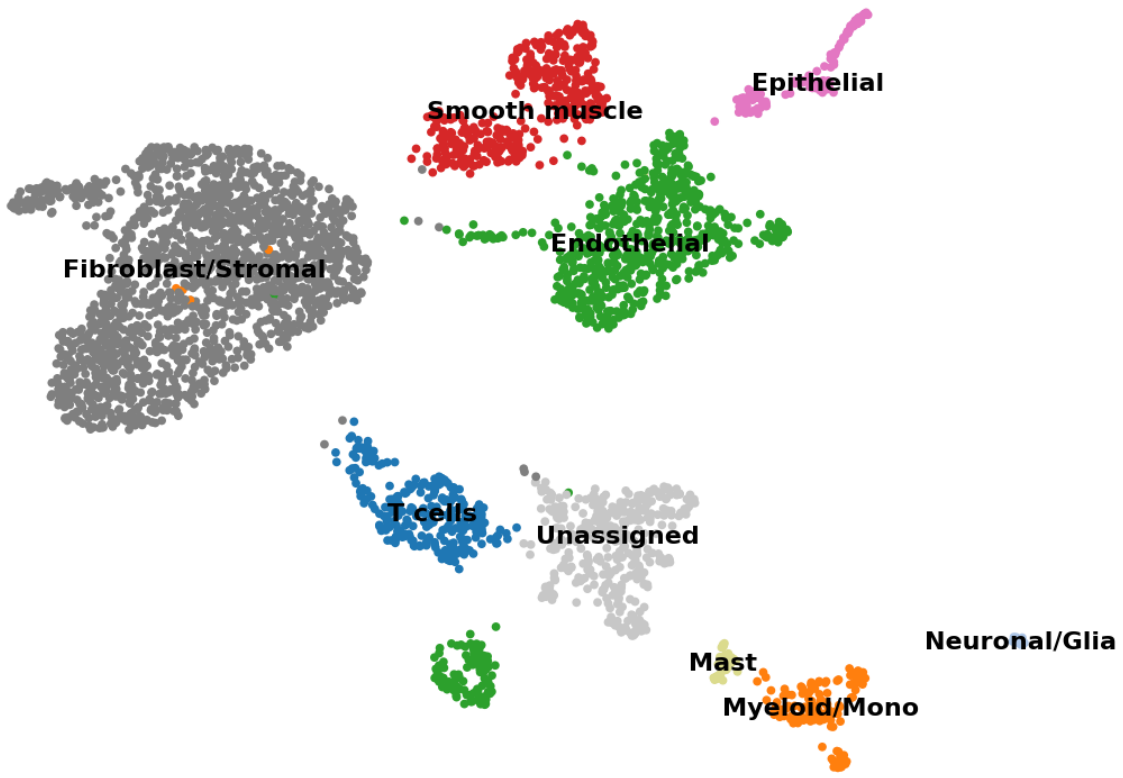


Рис. 4 Образец SRR14762241 UMAP с названиями кластеров: Epithelial, Smooth muscle, Endothelia, Fibroblast/Stromal, Tcells, Unassigned, Neuronal/Glia, Mast, Myeloid/Mono.

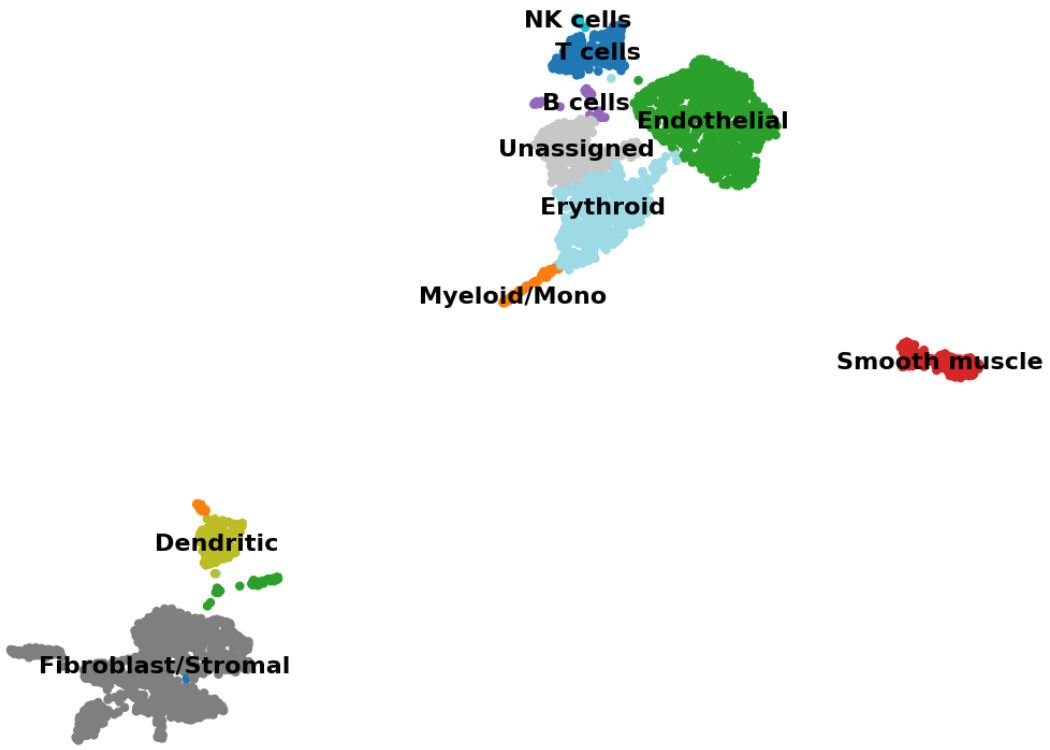


Рис. 5 Образец SRR14762242 UMAP с названиями кластеров: NK cells, T cells, B cells, Endothelial, Unassigned, Erythroid, Myeloid/Mono, Smooth muscle, Dendritic, Fibroblast/Stromal.

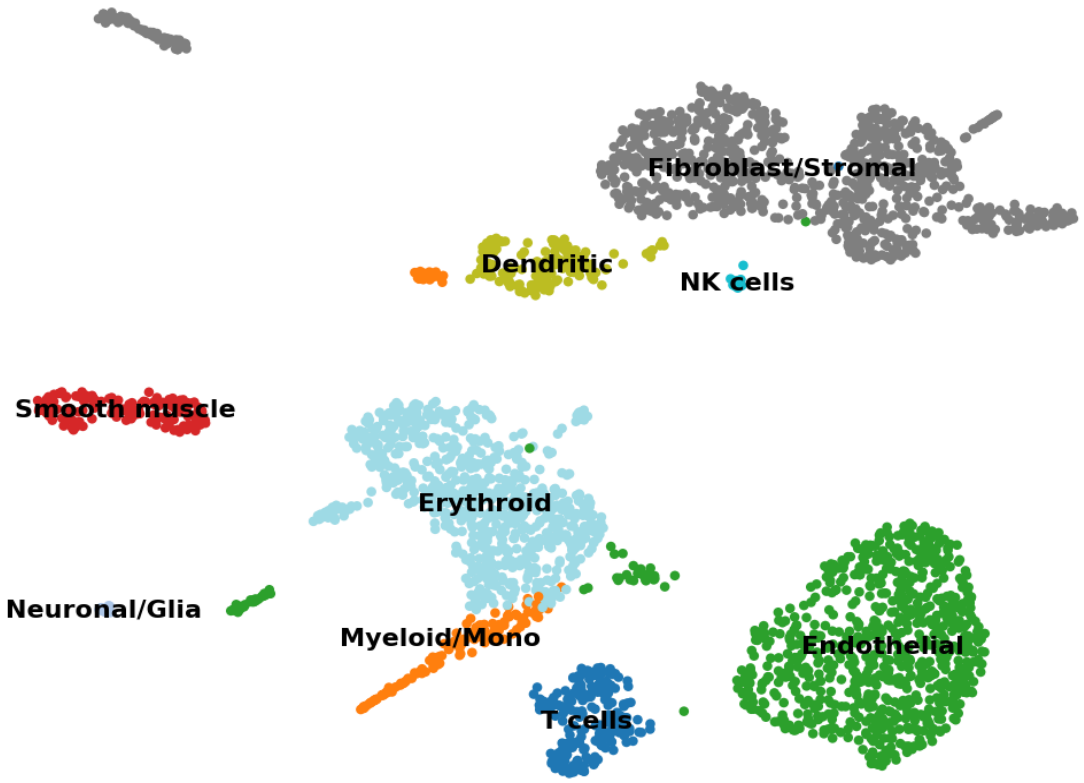


Рис. 6 Образец SRR14762243 UMAP с названиями кластеров: NK cells, T cells, Endothelial, Erythroid, Smooth muscle, Dendritic, Fibroblast/Stromal, Neuronal/Glia.

**Обсуждение**

Разработанный пайплайн является воспроизводимым и надежным инструментом для комплексного анализа scRNA-seq данных. Он успешно функционирует в среде Windows/WSL и генерирует все необходимые артефакты для детальной биологической интерпретации. Пайплайн обладает высокой расширяемостью, позволяя включать батч-коррекцию для анализа многопробных наборов данных и проводить дальнейшие биологические исследования, такие как анализ обогащения путей и межклеточных взаимодействий. Рассматриваемый конвейер укладывается в парадигму DS/ML: модульность, наблюдаемость, воспроизводимость. Слабонаблюдаемая аннотация (маркерная + референсная) обеспечивает баланс между интерпретируемостью и автоматизацией. В дальнейшем возможно включение полугосподствующих моделей (label propagation), объединённых вероятностных ансамблей и self-supervised представлений по сырым матрицам экспрессии.

**Воспроизводимость**

Конвейер описан декларативно; среды — conda; фиксируем версии инструментов и параметры запуска. Артефакты (матрицы 10x, UMAP, маркёры, отчёты) кэшируются; индексы и референсы (GENCODE[11]) валидируются контрольными хешами. Конвейер готов к контейнеризации и CI.

Все версии инструментов (STAR/STARsolo[1,2], Scanpy/AnnData[3,4], Harmony[17], cellsnp-lite[12], VarTrix[13]) и ключевые параметры зафиксированы; конфигурации пайплайна описаны декларативно; артефакты кэшируются. Конвейер разворачивается в Windows/WSL с идентичной логикой путей и контрольными хешами входных/выходных файлов.

В статье формализуется анализ как конвейер обработки данных с явными стадиями извлечения, валидации и преобразований; описываем метрики качества (количество генов на клетку, pct_mt, доля дублетов), процедуры отбора переменных (HVG[7]) и снижения размерности (PCA[9], UMAP[5]) с последующей кластеризацией (Leiden[6]) и автоматической аннотацией (Azimuth[14]/CellTypist[15,16]). Реализация на Windows/WSL подчёркивает воспроизводимость, переносимость и инженерные практики MLOps.

Интегрированный анализ экспрессии генов и мутаций на уровне одиночных клеток

**Информация о финансировании**. Данное исследование финансируется Комитетом науки Министерства образования и науки Республики Казахстан (грант № AP22686112 «Исследование соматических мутаций по данным одноклеточной РНК с использованием методов машинного обучения у пациентов с заболеванием периферических артерий»).

**Доступность данных и кода**

Данные: NCBI SRA PRJNA736095 (SRR-подмножества из статьи). Референсы: GENCODE v43 (GRCh38) [11]. Код/конфигурации: описаны в документе; при необходимости готовы к публикации как репозиторий с инструкциями запуска (Windows/WSL).

Github: https://github.com/exqusem/---ML--scRNA-seq-weak-supervision-.git

**Список источников**

1. Dobin A., Davis C.A., Schlesinger F., et al. STAR: ultrafast universal RNA-seq aligner. Bioinformatics. 2013;29(1):15–21. doi:10.1093/bioinformatics/bts635 (URL: https://doi.org/10.1093/bioinformatics/bts635)
2. Kaminow B., Yunusov D., Dobin A. STARsolo: accurate, fast and versatile mapping/quantification of single-cell and single-nucleus RNA-seq data. bioRxiv. 2021. doi:10.1101/2021.05.05.442755 (URL: https://doi.org/10.1101/2021.05.05.442755)
3. Wolf F.A., Angerer P., Theis F.J. SCANPY: large-scale single-cell gene expression data analysis. Genome Biology. 2018;19:15. doi:10.1186/s13059-017-1382-0 (URL: https://doi.org/10.1186/s13059-017-1382-0)
4. Virshup I., Rybakov S., Theis F.J., Angerer P., Wolf F.A. anndata: Access and store annotated data matrices. JOSS. 2024;9(101):4371. doi:10.21105/joss.04371 (URL: https://doi.org/10.21105/joss.04371)
5. McInnes L., Healy J., Melville J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv:1802.03426 (2018). (URL: https://arxiv.org/abs/1802.03426)

6. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities. Scientific Reports. 2019;9:5233. doi:10.1038/s41598-019-41695-z (URL: https://doi.org/10.1038/s41598-019-41695-z)

7. Stuart T., Butler A., Hoffman P., et al. Comprehensive Integration of Single-Cell Data. Cell. 2019;177(7):1888–1902.e21. doi:10.1016/j.cell.2019.05.031 (URL: https://doi.org/10.1016/j.cell.2019.05.031)

8. Luecken M.D., Theis F.J. Current best practices in single-cell RNA-seq analysis: a tutorial. Mol Syst Biol. 2019;15(6):e8746. doi:10.15252/msb.20188746 (URL: https://doi.org/10.15252/msb.20188746)

9. Jolliffe I.T. Principal Component Analysis. 2nd ed. Springer. 2002. doi:10.1007/b98835 (URL: https://doi.org/10.1007/b98835)

10. Leinonen R., Sugawara H., Shumway M. The Sequence Read Archive. Nucleic Acids Research. 2011;39(Database):D19–D21. doi:10.1093/nar/gkq1019 (URL: https://doi.org/10.1093/nar/gkq1019)

11. Frankish A., Diekhans M., Jungreis I., et al. GENCODE 2021. Nucleic Acids Research. 2021;49(D1):D916–D923. doi:10.1093/nar/gkaa1087 (URL: https://doi.org/10.1093/nar/gkaa1087)

12. Huang X., Huang Y. cellsnp-lite: an efficient tool for genotyping single cells. Bioinformatics. 2021;37(23):4569–4571. doi:10.1093/bioinformatics/btab358 (URL: https://doi.org/10.1093/bioinformatics/btab358)

13. 10x Genomics. VarTrix: Single-Cell Genotyping Tool. GitHub repository. v1.x. (URL: https://github.com/10XGenomics/vartrix)

14. Hao Y., Hao S., Andersen-Nissen E., et al. Integrated analysis of multimodal single-cell data. Cell. 2021;184(13):3573–3587.e29. doi:10.1016/j.cell.2021.04.048 (URL: https://doi.org/10.1016/j.cell.2021.04.048)

15. Domínguez Conde C., Xu C., Jarvis L.B., et al. Cross-tissue immune cell analysis reveals tissue-specific features in humans. Science. 2022;376(6594):eabl5197. doi:10.1126/science.abl5197 (URL: https://doi.org/10.1126/science.abl5197)

16. Xu C., Domínguez Conde C., van Dongen S., et al. Automatic cell-type harmonization and integration across Human Cell Atlas datasets. Cell. 2023;186(26):5876–5891.e20. doi:10.1016/j.cell.2023.11.026 (URL: https://doi.org/10.1016/j.cell.2023.11.026)

17. Korsunsky I., Millard N., Fan J., et al. Fast, sensitive and accurate integration of single-cell data with Harmony. Nature Methods. 2019;16(12):1289–1296. doi:10.1038/s41592-019-0619-0 (URL: https://doi.org/10.1038/s41592-019-0619-0)